

仮説条件付き実験選択は SBML の機構回復にも効くか: LLM-AutoSciLab の閉ループを SciGym に載せ、同じ LLM の ReAct エージェントと比べる事前登録研究

Anonymous authors

Paper under double-blind review

ABSTRACT

LLM-AutoSciLab (Kabra et al., 2026) は、複数の候補機構を明示的に持ち、候補どうしの予測が最も食い違う条件を次の実験に選ぶ閉ループの発見枠組みで、著者らのベンチマーク (NewtonBench、ActiveSciBench) では同じ実験予算で 2~5 倍のサンプル効率を報告している。ただし評価されたのはスカラー応答を返すオラクルであり、全種の濃度時系列が観測され、答えを SBML として提出する SciGym (Duan et al., 2025) の反応回復課題で同じ獲得則が効くかは示されていない。本研究は、SciGym のデータ (small 137 件)、実験の種類 (初期濃度の変更)、正解モデルへの問い合わせ予算 (20 回)、評価 (公式 Evaluator の STE / RMS / NTS) をすべて固定したまま、手法だけを LLM-AutoSciLab の閉ループに替える。仮説は「不完全モデルに足す反応の集合 + 速度則 + 自由定数」として表し、公式コードの `EnsembleClient` (small モデル meta/llama-3.1-8b の K 並列サンプル)、`LLMClient` (large モデル openai/gpt-6-luna の整理)、`FalsificationSelector.select` (食い違い最大の点の貪欲多様選択) を無改変で呼び、SBML 固有の部分 (反応集合の束ね、`scipy` による定数フィット、候補 SBML 間の log 濃度分散、ブートストラップ確信度、提出) をアダプタとして書く。比較相手は同じ gpt-6-luna で動かす SciGym 公式の ReAct エージェント、アブレーションは実験選択だけを仮説と無関係にした同じループである。実験前に 3 つの主張を凍結する: 手法 run の平均 STE が ReAct より 0.02 以上低い (c1)、アブレーションの平均 STE が手法 run より 0.01 以上高い (c2)、ReAct の RMS F1 が手法 run より 0.02 以上低い (c3)。

1 はじめに

LLM に科学的発見のサイクル全体を行わせる研究には、二つの流れがある。一つは SciGym (Duan et al., 2025) のように、LLM エージェントが摂動実験を要求し、返ってきたデータを解析し、機構を提出するまでを一つの会話の中で行わせ、その出来を測るベンチマークである。もう一つは LLM-AutoSciLab (Kabra et al., 2026) のように、発見を「進化する仮説集合の上での逐次実験計画」として定式化し、仮説を一つに絞らずに複数の候補機構を持ち、候補どうしの予測が最も食い違う条件を次の実験に選ぶ枠組みである。後者は、実験を自由記述の推論で選ぶ前者のエージェントに対し、どの実験が仮説を分けるかを計算で決める点が異なる。

LLM-AutoSciLab は、候補機構の食い違いに基づく実験選択 (仮説条件付き獲得) が固定予算のもとでサンプル効率を改善すると主張し (Kabra et al., 2026, s2.p2)、アブレーションではこの部品を外すと全ベンチマークで大きく低下したと報告している (Kabra et al., 2026, s2.p7)。しかし評価に使われたオラクルは、入力を与えると一つの値を返すノイズのない黒箱関数である (Kabra et al., 2026, s2.p5)。公式リポジトリに含まれる SciGym 向けのアダプタも、SBML の機構復元ではなくスカラーのシミュレータ応答を最適化するものだとして述べており (Kabra et al., 2026, s2.p14) (コード上は 3 種の初期濃度を入力、1 種の最終濃度を出力とする)、SciGym の課題そのもの (全種の時系列を観測し、欠けた反応を SBML として提出する) には当てられていない。著者らも、性能が LLM の仮説の質とパーサ・改良バックエンドの対応範囲に依存することを限界として挙げている (Kabra et al., 2026, s2.p8)。

一方 SciGym の側では、公式の ReAct エージェント (Duan et al., 2025, s1.p3) は実験の選び方に原理を持たない。論文は、初期濃度の変更という摂動が「戦略的に設計されれば」種の関係・反応の型・速度則・反応速度について多くの情報を与えると述べている (Duan et al., 2025, s1.p8) が、何をもって戦略的とするかはエージェントの推論に委ねられている。

本研究はこの二つを接続する。SciGym のデータ、実験の種類、予算、評価をすべて固定したまま、手法だけを LLM-AutoSciLab の閉ループに替え、同じ LLM で動かした SciGym 公式 ReAct と比べる。問いは「仮説条件付き獲得はスカラー応答のオラクルの外、すなわち時系列が観測され SBML を提出する機構回復でも効くか」である。判定は AIRAS の事前登録の枠組みに従い、仮説・判定基準・予測区間・実行条件を実験前に記録へ凍結し、実験後は計測値だけを流し込む。

2 関連研究

SciGym. SciGym (Duan et al., 2025) は BioModels 由来の SBML モデルから反応を取り除いたものをエージェントに渡し、エージェントは初期濃度を変えた摂動実験を要求し (Duan et al., 2025, s1.p4)、Python で解析し、最終的な SBML を提出する。提出は任意の時点で行え、反復数の上限は 20 である (Duan et al., 2025, s1.p1)。提出モデルが無効なら 3 回までのデバッグ反復が許され、それでも無効なら不完全モデルのまま採点される (Duan et al., 2025, s1.p2)。評価指標は、全種の時系列の対称平均絶対パーセント誤差である STE (Duan et al., 2025, s1.p5)、反応物と生成物の集合が一致した反応の F1 である RMS (修飾子まで要求する厳格版もある) (Duan et al., 2025, s1.p6)、種間の相互作用の F1 である NTS (Duan et al., 2025, s1.p7) の 3 つである。論文は計算資源の制約から small split の 137 件で 6 モデルを評価した (Duan et al., 2025, s1.p9)。AIRAS の先行研究は同じ Controller で現行モデルを評価しており、本研究の比較相手である gpt-6-luna の ReAct もそこで一度測られている (§5 の予測区間の根拠)。

LLM-AutoSciLab. LLM-AutoSciLab (Kabra et al., 2026) は、既存の LLM による発見システムの多くが表現固定かつ受動的で、事前に集めた静的データの上で事後的に仮説を生成・改良するにとどまる (Kabra et al., 2026, s2.p3) と指摘し、仮説を機構レベルの対象としてオンラインの実験選択に使う。1 ラウンドは、small モデルが候補仮説を K 個ずつ並列にサンブルし (論文設定 $K = 5$ (Kabra et al., 2026, s2.p9))、構造の骨格でクラスタして、クラスタ分布のエントロピーの変化が 0.1 を下回るか 20 個に達したら止め (Kabra et al., 2026, s2.p10)、large モデルがそれを本命・対抗案・探索領域に整理する仮説生成、候補機構の予測が最も食い違う点を選ぶ実験選択 (Kabra et al., 2026, s2.p6)、新データで候補の定数を合わせ直しブートストラップで確信度を測る改良からなる。確信度が閾値 (論文設定 0.9) を超えると不確実性サンプリングによる改良モードに切り替わる (Kabra et al., 2026, s2.p12)。論文は主モデルに GPT-4o-mini、small モデルに Qwen2.5-7B-Instruct を用い (Kabra et al., 2026, s2.p4)、アンサンブルのサンプリング温度は 1.0 である (Kabra et al., 2026, s2.p13)。

3 仮説と予測

以下は記録 (record.json) から生成された仮説・主張・判定基準・予測区間の一覧である。実験後は Observed と Verdict が計測値から埋められる。

Hypothesis 1. LLM-AutoSciLab の仮説条件付き獲得 (候補機構の予測が最も食い違う実験を選ぶ) は、著者らが評価したスカラー応答のオラクル (NewtonBench / ActiveSciBench) の外でも機構回復を改善する。具体的には、全種の濃度時系列が観測され SBML を提出する SciGym-small の反応回復課題で、同じ gpt-6-luna を主モデルに使ったとき、SciGym 公式の ReAct エージェント (実験を自由記述の推論で選ぶ) より低い STE と高い RMS を出し、その改善は実験選択則によるものである。 (Kabra et al., 2026, s2.p2, s2.p3, s2.p5, s2.p8, s2.p14), (Duan et al., 2025, s1.p3, s1.p8)

Claim 1 SciGym-small 137 件の平均 STE (trajectory_smape) は、LLM-AutoSciLab の SciGym 用ループ (autosci-lab-luna) の方が SciGym 公式 ReAct エージェント (react-luna) より 0.02 以上低い。 (Kabra et al., 2026, s2.p1, s2.p2, s2.p6, s2.p9, s2.p10, s2.p11, s2.p12, s2.p13, s2.p15, s2.p16, s2.p19, s2.p22, s2.p23, s2.p24), (Duan et al., 2025, s1.p4, s1.p5, s1.p10, s1.p12) *Rationale:* h1 の中心。同じ主モデル・同じ実験予算・同じ 137 件・同じ公式 Evaluator で、手法だけを替えたときの差が STE に

出れば、仮説条件付きの閉ループが SBML の機構回復にも効くという h1 の主張の直接の証拠になる。*Criterion:* `autoscilab-luna.trajectory_smape - react-luna.trajectory_smape` ≤ -0.02 . *Prediction:* $[-0.1, -0.02]$ (同じ `openai/gpt-6-luna` の公式 ReAct は `auto-res2/scigym-frontier-models` (137 件、`max_iterations=20`) で STE 0.2295 だった。論文は同じ予算で 2-5 倍のサンプル効率 (s2.p1) を報告しているが、SBML への翻訳とフィットはこちらのアダプタなので、改善幅は 0.02~0.10 と控えめに見積もる。). *Observed:* pending. *Verdict:* pending.

Claim 2 同じループで実験選択だけを仮説と無関係にした `autoscilab-nohyp-luna` の平均 STE は、`autoscilab-luna` より 0.01 以上高い。(Kabra et al., 2026, s2.p7, s2.p11, s2.p22) *Rationale:* h1 の「改善は実験選択則によるもの」の部分。論文で最も効いた部品 (s2.p7) を外した run との差が出れば、c1 の差が仮説生成やフィットではなく仮説条件付き獲得に帰せられる。*Criterion:* `autoscilab-nohyp-luna.trajectory_smape - autoscilab-luna.trajectory_smape` ≥ 0.01 . *Prediction:* $[0.01, 0.08]$ (論文の Figure 4 では仮説条件付き獲得を外すと全ベンチマークで大きく落ちる (s2.p7)。SciGym では実験 20 回のうち情報の薄い点が増える分の差として 0.01~0.08 と見積もる。). *Observed:* pending. *Verdict:* pending.

Claim 3 SciGym 公式 ReAct エージェント (`react-luna`) の RMS (修飾子なしの `reaction_f1`) は、`autoscilab-luna` より 0.02 以上低い。(Duan et al., 2025, s1.p1, s1.p2, s1.p3, s1.p4, s1.p6, s1.p10, s1.p11) *Rationale:* h1 の RMS の部分。STE は軌道の近さしか見ないので、反応の構造が実際に回復されているかは RMS で確かめる。`react-luna` はこの claim の run であると同時に c1 の比較対象でもある。*Criterion:* `react-luna.reaction_f1 - autoscilab-luna.reaction_f1` ≤ -0.02 . *Prediction:* $[-0.15, -0.02]$ (同じ `openai/gpt-6-luna` の公式 ReAct は `auto-res2/scigym-frontier-models` で `reaction_f1` 0.3594 だった。SciGym 論文 Table 1 の RMS F1 (修飾子なし) はモデル間で 0.10~0.34 の幅 (s1.p10) なので、手法の差として 0.02~0.15 を見積もる。). *Observed:* pending. *Verdict:* pending.

Assumed, so that the claims together imply Hypothesis 1:

- STE / RMS / NTS (SciGym 公式 Evaluator、`airas-eval scigym_small`) が機構回復の良さを表す (c1, c2, c3)
- アダプタが SciGym の設定を LLM-AutoSciLab の手法に写す仕方 (仮説 = 不完全モデルに足す反応の集合 + 速度則、実験 = 初期濃度の変更、食い違い = 候補 SBML の濃度時系列の対数分散) が手法の意図を保っている (c1, c2, c3)
- 上流コード (`scientific-discovery/LLM-AutoSciLab @351aae7, h4duan/SciGym @88a7b93`) はそれぞれの論文を実装している (c1, c2, c3)
- knob の一覧 (design の arguments) は、コードから列挙できた範囲を超えて完全である (c1, c2, c3)
- Vercel AI Gateway が返すモデル (`openai/gpt-6-luna`、`meta/llama-3.1-8b`) はその名前のモデルである (c1, c2, c3)
- LLM のサンプリングは非決定的であり、1 回の run の差は再現時にずれうる (c1, c2, c3)
- GitHub Actions の実行記録と git 履歴は正しい (c1, c2, c3)
- ReAct の `max_iterations=20` と AutoSciLab のオラクル問い合わせ 20 回を同じ実験予算とみなす (ReAct の反復にはコード実行だけの反復も含まれるので、ReAct の実験回数は 20 以下になる) (c1, c3)

判定基準と予測区間の根拠. c1 の反証線は「(手法 run の平均 STE) - (ReAct の平均 STE) ≤ -0.02 」である。同じ `openai/gpt-6-luna` の公式 ReAct は、AIRAS の先行研究 (`auto-res2/scigym-frontier-models`, 137 件、最大 20 反復) で平均 STE 0.2295 であった。マージン 0.02 はこの約 10% にあたり、同じモデルを 2 回走らせたときの LLM サンプリングのばらつき (1 件の STE の標準偏差を 0.27 程度と見積もると 137 件平均の標準誤差は約 0.02) を超える差として置いた。予測区間 $[-0.10, -0.02]$ は、論文の 2~5 倍のサンプル効率 (Kabra et al., 2026, s2.p1) をそのまま信じず、SBML への翻訳とフィットが本研究のアダプタである分を割り引いたものである。c2 のマージン 0.01 はアブレーションの差が小さくなりうることを見込んで半分にした。予測区間 $[0.01, 0.08]$ は、論文がこの部品を外すと全ベンチマークで

大きく低下したと報告していること (Kabra et al., 2026, s2.p7) を手がかりに、SciGym では実験 20 回のうち情報の薄い点が増える分の差として本研究が見積もったもので、数値そのものは論文にはない。c3 は STE が軌道の近さしか見ないことを補い、反応の構造が実際に回復されているかを RMS F1 (修飾子なし) で確かめる。同じ先行研究で ReAct の reaction_f1 は 0.3594 であり、SciGym 論文 Table 1 では例えば GPT-4.1-mini 行の RMS F1 (修飾子なし) が 0.2322 である (Duan et al., 2025, s1.p10)。モデル間の差がこの程度の幅で現れることから、手法の差として [0.02, 0.15] を見積もる。NTS、修飾子ありの RMS、提出数、1 件あたりの実験回数、トークン数は同じ実行から表として報告するが、判定には用いない。

4 方法

課題と固定するもの. 各件は真の SBML、反応をすべて取り除いた不完全な SBML、シミュレーション条件 (SED-ML) からなる。正解モデルへの問い合わせは SciGym の `Experiment.call_simulator` (Duan et al., 2025, s1.p12) を通して行い、本研究ではこれを正解モデルに触る唯一の口とする。摂動は論文と同じく初期濃度の変更 (Duan et al., 2025, s1.p4) である。観測する種を指定しない呼び出しでは全種の時系列が返る (SciGym 公式コードの振る舞い)。本研究では 3 つの run すべてで、この問い合わせを 1 件あたり最大 20 回に揃える。提出 SBML は airas-eval の `scigym_small` パック (SciGym 公式の Evaluator をそのまま包んだもの) で採点する。

比較相手: SciGym 公式 ReAct (run react-luna). SciGym 公式コードのベンチマーク実行の入口は `run_benchmark(self, model: LLM)` である (Duan et al., 2025, s1.p11)。本研究はこの Controller を無改変で用い、LLM は `scigym.api.api.LLM` のサブクラスとして Vercel AI Gateway の OpenAI 互換エンドポイントを呼ぶアダプタだけを書く。反復数の上限 20 は論文と同じである (Duan et al., 2025, s1.p1)。無効な提出に対するデバッグ反復 3 回も論文と同じである (Duan et al., 2025, s1.p2)。temperature 1.0 は SciGym 公式コードの既定値である。SciGym の反復にはコード実行だけの反復も含まれるため、ReAct の実験回数は 20 以下になる。

手法: LLM-AutoSciLab の SciGym 用ループ (run autoscilab-luna). 公式 LLM-AutoSciLab のループは Python の式 (NewtonBench、ActiveSciBench-Chem) か 5 ノード固定のグラフ (ActiveSciBench-GRN) しか扱わないので、著者らが GRN 用のループを別に足したのと同じ形で、SBML 用のループをアダプタとして書く。仮説は「不完全モデルに足す反応の集合」で表す。各反応は反応物・生成物・活性化因子・阻害因子と速度則の形 (質量作用、Michaelis-Menten、Hill) を持ち、速度定数・飽和定数・Hill 係数は自由定数とする。骨格は反応集合 (反応物・生成物・修飾子の組) で、速度則の形と定数は含めない。1 件の流れは次のとおりである。

1. 最初の問い合わせは既定の初期条件での観測とする。
2. 仮説生成。small モデル (meta/llama-3.1-8b) を公式 `EnsembleClient.complete_json_k` で $K = 5$ ずつ並列に呼び、骨格で束ね、エントロピーの変化が 0.1 未満になるか 20 個に達するまで続ける (Algorithm 2 の規則。公式の `EnsembleAgent` は Python 式の仮説しか解釈しないので、束ね方だけアダプタで同じ規則を書く)。large モデル (openai/gpt-6-luna) を公式 `LLMClient.complete_json` で呼び、本命 1 つ・対抗案 2~6 個・探索領域 (変えてよい種と初期濃度の範囲。既定値の 0.2~5 倍の中) に整理する。
3. 各候補の自由定数を、これまでの実験の時系列 (全種 $\times$ 全時刻、log スケール) に対して `scipy` で最小二乗フィットする。
4. 実験選択。公式 `FalsificationSelector.select` (候補点 2000、多様性 0.3) に、種 id と濃度範囲だけを返すオラクル役 (`BaseOracle` のサブクラス) と、候補 SBML を SciGym の `Simulator` で回して全種・全時刻の log 濃度の候補間分散を返す仮説分布役を渡し、常に 4 点を選ぶ (予算の残りが 4 未満なら先頭だけ使う)。
5. 選んだ初期濃度の組を `Experiment.call_simulator` に投げ、全種の時系列を得る。
6. 改良。候補を再フィットし、実験の再標本化 (3 回) で再フィットした予測のばらつきから確信度 $= 1 - \text{正規化 std}$ を計算する (公式 `learner.py` の定義。同じく log 空間の R^2 が 0.5 未満の候補は確信度 0)。0.9 以上なら改良モードに切り替え、再フィットどうしの予測が最も割れる点を選ぶ。

7. 予算を使い切ったら、フィット誤差が最小の候補 SBML を提出する。妥当な候補が無い件は提出なしとし、不完全モデルのまま採点される。

公式コードから無改変で呼ぶのは `EnsembleClient`、`LLMClient`、`FalsificationSelector.select` であり、PySR による記号回帰、`DiscoveryLoop`、`HypothesisDistribution`、`LLMMemory` は Python 式専用のため使わない。公式リポジトリの SciGym 用アダプタ (スカラー縮約) も使わない。

アブレーション (run autoscilab-nohyp-luna) . 同じループ・同じモデル・同じ予算で、`FalsificationSelector.select` に渡す食い違いスコアを全候補点で 0 にする。貪欲選択は多様性項だけで点を選ぶので、実験は仮説と無関係に濃度空間を埋める配置になる。論文は仮説条件付き獲得を外すアブレーションで全ベンチマークの性能が大きく低下したと報告しているが (Kabra et al., 2026, s2.p7)、その実装の詳細は述べていないので、ここでの実装は本研究が対応させたものである。

記録と検証. 記録には SciGym (コミット 88a7b93) と LLM-AutoSciLab (コミット 351aae7) のコードスナップショットを固定し、各 run の design にどの上流関数をどの引数で呼ぶか (`n_candidates = 2000`, `diversity_weight = 0.3`, `select` の `n = 4`, `EnsembleClient` の `k = 5`・`temperature 1.0`・`max_tokens 4096`, `LLMClient` の `max_completion_tokens 8192`, `ReAct` の `max_iterations 20`・`eval_debug_rounds 3`・`temperature 1.0`) を宣言する。実行時の観測フックが実際の呼び出しと読み込んだ上流ファイルのハッシュを記録し、記録の宣言と突き合わせる。

5 実験設計

データと評価. SciGym の small split 137 件。評価は airas-eval scigym_small の STE (trajectory_smap), RMS F1 (reaction_f1, 修飾子なし)、修飾子ありの RMS F1、NTS F1 (topology_f1)。

run. react-luna (SciGym 公式 ReAct, openai/gpt-6-luna、最大 20 反復)、autoscilab-luna (手法、large = openai/gpt-6-luna、small = meta/llama-3.1-8b、問い合わせ 20 回、1 反復 4 実験)、autoscilab-nohyp-luna (アブレーション、食い違いスコア 0)。run と主張の対応は、`c1 ← autoscilab-luna` (比較対象は react-luna)、`c2 ← autoscilab-nohyp-luna` (比較対象は autoscilab-luna)、`c3 ← react-luna` (比較対象は autoscilab-luna) である。

LLM. 論文は主モデルに GPT-4o-mini、small モデルに Qwen2.5-7B-Instruct を用いた (Kabra et al., 2026, s2.p4)。本研究では large を比較相手と同じ openai/gpt-6-luna とし、small は Qwen2.5-7B-Instruct が Vercel AI Gateway に無いため、同じ 7~8B の dense な instruct モデルで thinking を持たない meta/llama-3.1-8b で代える (出力上限 8192 トークンが公式既定の max_tokens 4096 を満たす)。アンサンブルの温度は論文の 1.0 (Kabra et al., 2026, s2.p13) (公式コードの既定値は 0.9)。

予算の揃え方. 3 run とも正解モデルへの問い合わせを 1 件 20 回で揃える。ReAct の 20 反復にはコード実行だけの反復も含まれるので、ReAct の実験回数は 20 以下になる。両方で 1 件あたりの実験回数とトークン数を記録し、表に出す。LLM の呼び出し回数は手法 run の方が多い (small モデル K 回 × 反復)。

計算環境と手順. GitHub Actions のランナー ubicloud-standard-2 (x86_64、2 vCPU、8 GB、GPU なし)。1 run = 1 job、1 件 1 プロセス。候補 SBML の再シミュレーションは 1 回 0.3~2.2 ms なので、2000 候補 × 5 仮説 × 5 反復でも 1 件あたり数分である。手順は sanity (1 件、予算 9 / 2 反復) → 凍結 → pilot (10 件) → full (137 件 × 3 run)。sanity の出力は証拠にせず、pilot と full は凍結コミットの子孫で実行する。

6 結果

(実験後に記入)

7 考察

(実験後に記入)

8 結論

(実験後に記入)

データの利用可能性

記録は record.json にある。実験コード、環境の固定 (Dockerfile と uv.lock)、各 run の結果と provenance は同じリポジトリに含まれる。

REFERENCES

Haonan Duan, Stephen Z. Lu, Caitlin F. Harrigan, Nishkrit Desai, Jiarui Lu, Michał Koziarski, Leonardo Cotta, and Chris J. Maddison. Measuring scientific capabilities of language models with a systems biology dry lab. *NeurIPS 2025*, 2025. doi: 10.48550/arXiv.2507.02083. URL <https://arxiv.org/pdf/2507.02083>. code: <https://github.com/h4duan/SciGym> at commit 88a7b93609e35b6ecb4eb343d816d6ff09256c6a.

Sanchit Kabra, Nikhil Abhyankar, Saaketh Desai, Prasad Iyer, and Chandan K. Reddy. Llm-autosilab: Closed-loop scientific discovery via active experimentation with llms. *NeurIPS 2026*, 2026. URL <https://arxiv.org/pdf/2605.24043>. code: <https://github.com/scientific-discovery/LLM-AutoSciLab> at commit 351aae73e6c6c279e67943b77143b0f118d1e289.